

Aprendizaje social en enjambres de robots mediante imitación entre individuos

Jonatan Díaz, *Student Member*, Wilson Achicanoy, *Member*, David Garzón Ramos, *Member*

Abstract—La robótica de enjambres estudia el despliegue de grandes grupos de robots de forma escalable y auto-organizada. En este trabajo se presentan primeros resultados en la experimentación con aprendizaje social en enjambres de robots mediante la imitación de movimientos entre individuos. Este trabajo de investigación propone un método donde un robot “aprendiz” observa simultáneamente a múltiples compañeros “maestros” y, procesando información parcial en tiempo real, logra abstraer y aprender el comportamiento demostrado basándose únicamente en su percepción local.

Index Terms—aprendizaje social, embodied imitation, inteligencia descentralizada, robótica de enjambres.

I. INTRODUCCIÓN

EL aprendizaje social es un proceso de acumulación y transmisión de información entre individuos mediante interacciones locales [1]. Este aprendizaje se ha observado originalmente en sistemas biológicos; estudios recientes en insectos sociales como las abejas demuestran que este mecanismo les permite aprender comportamientos complejos. Por ejemplo, Alice D. Bridges et al, en su investigación: “Bumblebees socially learn behaviour too complex to innovate alone”, lograron que abejas inexpertas aprendieran a resolver un rompecabezas secuencial para obtener alimento, basándose únicamente en la observación de un congénere entrenado [7]. Un campo interesante para aplicar este tipo de aprendizaje es el diseño de enjambres de robots [5]: grupos numerosos de robots simples que cooperan para realizar tareas que exceden sus capacidades individuales [4], [6].

En el futuro, se podrán implementar enjambres que realicen labores como agricultura, atención en escenarios de desastres y manejo de paquetería [9]. Estos enjambres pueden beneficiarse de un despliegue progresivo de los robots. Un ejemplo de esto ocurre cuando, en la ejecución de una tarea, se comienza con un número pequeño de robots y, posteriormente, se debe aumentar el número de estos, ya sea para agilizar la ejecución de la tarea o por requerimientos emergentes. Para lograr esta escalabilidad, resulta interesante que los robots posean la capacidad de aprender comportamientos por sí mismos, observando a sus pares. Por ello, se propuso dotar a los robots en un enjambre de la capacidad de aprender socialmente mediante la imitación directa de robot a robot, utilizando únicamente sus propios sensores a bordo. Este mecanismo es conocido en la literatura como *embodied imitation* y fue empleado por Alan Winfield et al. [2]. Ellos demostraron que

un robot es capaz de aprender patrones de movimiento al observar la trayectoria de un maestro, esto mediante señales visuales simples, como el uso de LEDs.

Este modelo fue evaluado en escenarios en los que un solo robot aprende de otro de forma aislada. Al escalar el proceso a condiciones de enjambre, caracterizadas por operar en un entorno dinámico y poblado, enfocarse en un único demostrador desaprovecha información valiosa que otros robots en el entorno podrían aportar. Para abordar este problema, en este trabajo se consideran dos tipos de roles: los robots “maestros” (R_{m_i}), que ejecutan un comportamiento, y el robot “aprendiz” (R_a), que los observa. La novedad de este trabajo radica en llevar la *embodied imitation* un paso más allá: diseñar un método en el que el robot observador logre aprender abstrayendo y procesando información simultánea y parcial. Los hallazgos iniciales demuestran que, al procesar fragmentos de información de múltiples maestros, un robot en un enjambre es capaz de reconstruir y replicar patrones de movimiento como trayectorias poligonales.

II. METODOLOGÍA

La metodología de esta investigación adapta los principios teóricos de la *embodied imitation* para aplicarlos en un método de aprendizaje social en enjambres de robots. Inicialmente, se definieron reglas locales donde el procesamiento visual simple permite al robot identificar a sus pares. Posteriormente, se diseñó e implementó el software de control, programando el ciclo interno del robot: observación del entorno; procesamiento de los datos parciales obtenidos de los maestros, donde el aprendiz integra la información mediante regresiones lineales y solapamiento de nubes de datos para reconstruir el patrón de movimiento demostrado; finalizando con la ejecución del comportamiento aprendido.

Para la evaluación experimental, se configuró un entorno de enjambre en el simulador ARGoS3 [3]. Se utilizó como modelo el robot QUPA (ver Figura 1), una plataforma desarrollada en la Escuela Superior Politécnica del Litoral (ESPOL), Ecuador, equipada con sensores infrarrojos y LEDs direccionales para emitir señales visuales. Como se observa en la Figura 2, el escenario consiste en una arena de 3 x 3 metros, poblada por siete R_{m_i} y un R_a (en el centro). Los R_{m_i} ejecutan continuamente un patrón poligonal encendiendo sus LEDs, mientras que el R_a utiliza su percepción local para aprender de ellos.

III. RESULTADOS

Durante la ejecución en la arena, el robot aprendiz R_a procesó los fragmentos obtenidos de la percepción local de los




Fig. 1. Vista del modelo del robot QUPA implementado en ARGoS3. La plataforma está equipada con sensores infrarrojos para la percepción local y LEDs direccionales para la emisión de señales visuales.




Fig. 2. A la izquierda, configuración de la arena de simulación poblada por el enjambre. A la derecha, representación gráfica de los datos parciales captados por el robot aprendiz a partir de su línea de visión local.

R_{m_i} y reconstruyó exitosamente los patrones de movimiento. Se evaluaron dos trayectorias principales: un triángulo y un pentágono irregular.




Fig. 3. Trayectorias parciales captadas por el aprendiz (extremos) y patrón continuo reconstruido en su centro.

Para evaluar cuantitativamente la fidelidad del comportamiento aprendido, se adoptaron las métricas de calidad propuestas originalmente por Winfield et al. [2]. Estas métricas evalúan el error en tres componentes normalizados entre 0 y 1: precisión en la longitud de los segmentos (Q_l), exactitud en los ángulos de giro (Q_a) y el número total de segmentos reproducidos (Q_s). La integración de estos tres parámetros proporciona la calidad global de imitación (Q_i).

La Figura 4 evidencia visualmente la alta similitud entre las figuras originales y las imitadas. Estos resultados se respaldan en la Tabla I, donde el robot aprendiz logró un $Q_s = 1.00$ en ambos escenarios (identificó correctamente el número de




Fig. 4. Comparativa superpuesta: patrón original (azul) vs. imitado (rojo).

TABLE I
MÉTRICAS DE CALIDAD DE IMITACIÓN

Patrón Demostrado	Q_l	Q_a	Q_s	Q_i (Global)
Triángulo	0.98	0.99	1.00	0.99
Pentágono Irregular	0.97	0.99	1.00	0.98

segmentos). Adicionalmente, las métricas de longitud y ángulo superaron el 0.97 de precisión. En consecuencia, se alcanzó una calidad global (Q_i) alta, superando el 0.98 (98% de fidelidad) en ambas pruebas. Estos datos confirman que el aprendizaje a partir de múltiples demostradores es posible y preciso.

IV. CONCLUSIONES

Los resultados obtenidos evidencian que abstraer y procesar información simultánea permite trasladar el mecanismo de *embodied imitation* a condiciones dinámicas de enjambre. Como trabajo futuro, se evaluará el método desplegando progresivamente más robots en la arena, analizando si, en estas condiciones, la efectividad del aprendizaje se mantiene o si el comportamiento observado se degrada.

REFERENCES

- [1] M. S. Reed *et al.*, “What is Social Learning?,” *Ecology and Society*, vol. 15, no. 4, 2010.
- [2] M. D. Erbas, L. Bull, and A. F. T. Winfield, “On the Evolution of Behaviors through Embodied Imitation,” *Artificial Life*, vol. 21, no. 2, pp. 141–165, 2015.
- [3] C. Pinciroli *et al.*, “ARGoS: A modular, parallel, multi-engine simulator for multi-robot systems,” *Swarm Intelligence*, vol. 6, no. 4, pp. 271–295, 2012.
- [4] M. Brambilla, E. Ferrante, M. Birattari, and M. Dorigo, “Swarm robotics: a review from the swarm engineering perspective,” *Swarm Intelligence*, vol. 7, no. 1, pp. 1–41, 2013.
- [5] D. Garzón Ramos and S. Hauert, “Designing robot swarms: a puzzle, a problem, and a mess,” 2024.
- [6] E. Şahin, “Swarm robotics: from sources of inspiration to domains of application,” in *Swarm Robotics. SAB 2004*, ser. Lecture Notes in Computer Science, vol. 3342. Springer, 2005, pp. 10–20.
- [7] A. D. Bridges, A. Royka, T. J. Czaczkes, and L. Chittka, “Bumblebees socially learn behaviour too complex to innovate alone,” *Nature*, vol. 627, no. 8005, pp. 572–578, 2024.
- [8] L. Cazenille *et al.*, “Signalling and social learning in swarms of robots,” *Philosophical Transactions of the Royal Society A*, vol. 383, p. 20240148, 2025.
- [9] “Swarm robotics: principles, research and applications,” *Industrial Robot*, vol. 53, no. 1, pp. 1–7, 2025.